Računarski fakultet

UNIVERZITET UNION

Razvoj i evaluacija genetskog algoritma za selekciju placentnih gena u predikciji retinopatije prematuriteta

DIPLOMSKI RAD

MENTOR

prof. dr Jelena Vasiljević

KANDIDAT

Aleksandra Crnatović
Broj indeksa: 43/2021 RI

Beograd, 2026.

Apstrakt

Retinopatija prematuriteta (ROP) je jedan od vodećih uzroka slepila kod prevremeno rođene dece. Ovaj rad ispituje da li genetski algoritam može da izabere mali, prediktivan skup gena iz placentnog transkriptoma i koliko je taj izbor pouzdan na skupu od svega 30 uzoraka (14 sa ROP-om, 16 bez), uz 60.664 gena po uzorku. Nakon normalizacije i diferencijalne ekspresione analize, genetski algoritam bira podskup gena iz kandidatnog skupa od 124 gena, a performanse se procenjuju ugnježdenom unakrsnom validacijom kako bi se izbegao *selection bias*. Genetski algoritam postiže prosečan AUC od $0{,}919 \pm 0{,}068$, više od Random Forest baseline-a, Ridge, LASSO i elastic-net regresije, uz znatno manji broj gena. Dodatne provere (permutacioni test, isključivanje gena iz literature, zamena DEG metode) pokazuju da procena performansi nije bitno osetljiva na te izbore, dok je identitet pojedinačno biranih gena nestabilan. Gen HELLPAR, dugačka nekodirajuća RNK aktivna u trofoblastu posteljice, u glavnoj konfiguraciji biran je u svih 10 nezavisnih pokretanja i ima najveći SHAP doprinos, ali se tumači kao hipoteza, ne kao potvrđen biomarker. Rad je proof-of-concept metodološkog pristupa; zaključci su ograničeni malim uzorkom i zahtevaju validaciju na nezavisnoj kohorti.

Ključne reči: genetski algoritam, izbor obeležja, retinopatija prematuriteta, placenta, ugnježdena unakrsna validacija, SHAP

Sadržaj

Apstrakt 2

1 Uvod 5
- 1.1 Retinopatija prematuriteta – klinička slika i mehanizam . . . 5
- 1.2 Uloga posteljice u riziku od ROP-a . . . 6
- 1.3 Mašinsko učenje u predikciji ROP-a . . . 6
- 1.4 Motivacija i cilj rada . . . 7

2 Pregled literature 9
- 2.1 Placentni geni kao biomarkeri ROP-a . . . 9
- 2.2 Genetski algoritmi za izbor obeležja u genomici . . . 9
- 2.3 Objašnjiva veštačka inteligencija u analizi genske ekspresije . . . 10

3 Podaci i metodologija 11
- 3.1 Opis skupa podataka . . . 11
- 3.2 Predobrada i normalizacija podataka . . . 11
- 3.3 Diferencijalna ekspresiona analiza . . . 12
- 3.4 Genetski algoritam za izbor gena . . . 13

3.4.1 Reprezentacija rešenja . . . 13
3.4.2 Funkcija prilagođenosti . . . 13
3.4.3 Genetski operatori . . . 14
3.4.4 Algoritam u celini . . . 15
3.5 Ugnježđena unakrsna validacija . . . 15
3.6 Poređenje sa alternativnim metodama izbora obeležja . . . 17
3.7 SHAP objašnjivost . . . 18
3.8 Mreža sličnosti pacijenata . . . 19
3.9 Implementacija . . . 19

4 Rezultati 22
4.1 Diferencijalna ekspresija gena . . . 22
4.2 Performanse genetskog algoritma i poređenje metoda . . . 23
4.2.1 Permutacioni test . . . 24
4.2.2 Provera uticaja unapred poznatih gena . . . 25
4.3 Konvergencija i osetljivost na hiperparametre . . . 25
4.4 Stabilnost izbora gena . . . 27
4.5 Eksplorativna analiza sličnosti pacijenata . . . 28
4.6 SHAP objašnjivost . . . 29

5 Diskusija 30
5.1 Poređenje sa prethodnim istraživanjem . . . 30
5.2 Biološka interpretacija - gen HELLPAR . . . 31
5.3 Ograničenja rada . . . 31
5.4 Budući rad . . . 32

6 Zaključak 34

Spisak slika

1.1 Pojednostavljena šema dvofazne patogeneze ROP-a i mogućeg ishoda u težim slučajevima . . . 5

3.1 Opšti tok metodologije primenjene u ovom radu. . . . 11
3.2 Levo: ukupan broj očitavanja po uzorku u sirovim podacima. Desno: raspodela vrednosti $\log_2$(CPM+1) po uzorku za 15.307 eksprimiranih gena (CPM ≥ 1 u najmanje 15 uzoraka). Sivo: bez ROP-a, plavo: ROP. . . . 12
3.3 Primer genetskih operatora na hromozomu od 12 gena (u radu 124). Turnirska selekcija bira hromozom sa najvišom vrednošću funkcije prilagođenosti među tri nasumično izabrana ($k = 3$; vrednosti su ilustrativne). Plavo polje označava uključen gen. Maska ukrštanja određuje za svaku poziciju da li potomak gen preuzima od prvog (R1) ili drugog roditelja (R2), a mutacija zatim invertuje jednu poziciju (crveni okvir). . . . 15

3.4 Šema ugnježdene unakrsne validacije. Spoljna petlja deli 30 uzoraka na pet delova i u svakoj iteraciji izdvaja 6 uzoraka za konačno testiranje. Unutrašnja petlja deli preostala 24 trening uzorka na četiri dela i koristi se samo za procenu funkcije prilagođenosti unutar genetskog algoritma. Test uzorci spoljne iteracije ne učestvuju ni u izboru gena ni u treniranju. 17
3.5 Slojevita organizacija implementacije. Svaki sloj odgovara jednoj fazi analize i koristi izlaz prethodnog sloja. 19

4.1 Vulkan grafik diferencijalne ekspresione analize (42.638 gena). Tačkaste linije označavaju pragove $p = 0{,}05$ i $|\log_2 FC| = 1$; obojene tačke su 121 kandidatni gen. 23
4.2 Poređenje AUC performansi genetskog algoritma i alternativnih metoda izbora obeležja. Prikazane su prosečne vrednosti i standardna devijacija preko 5 spoljnih iteracija ugnježdene validacije. 24
4.3 Ekspresija 10 gena finalnog modela (z-skor po genu), sa uzorcima sortiranim po ROP statusu. Geni su izabrani nad svih 30 uzoraka, pa vizuelna razlika između grupa ne predstavlja procenu prediktivnih performansi; ta procena data je u Sekciji 4.2. 25
4.4 Konvergencija genetskog algoritma za različite vrednosti verovatnoće mutacije. Niža stopa mutacije ($p_m = 0{,}01$) omogućava postepeniju, ali dugoročno superiorniju konvergenciju u odnosu na više stope mutacije, koje dovode do preranog zaustavljanja na lokalnom optimumu. 26
4.5 Mreža sličnosti pacijenata na osnovu ekspresije finalnog skupa gena. Čvorovi predstavljaju uzorke, obojeni prema ROP statusu (tamnoplavo – ROP, sivo – bez ROP-a); ivice povezuju uzorke sa najsličnijim profilom ekspresije ($k = 5$). . 28
4.6 SHAP objašnjivost finalnog modela. Svaka tačka predstavlja jedan uzorak; položaj na horizontalnoj osi pokazuje uticaj na predikciju rizika, a boja označava vrednost ekspresije posmatranog gena kod tog uzorka (plava – niska, bordo – visoka). 29

Spisak tabela

1.1 Pregled odabranih kliničkih algoritama za predikciju ROP-a. 7

3.1 Biblioteke korišćene u implementaciji i njihova uloga. 20

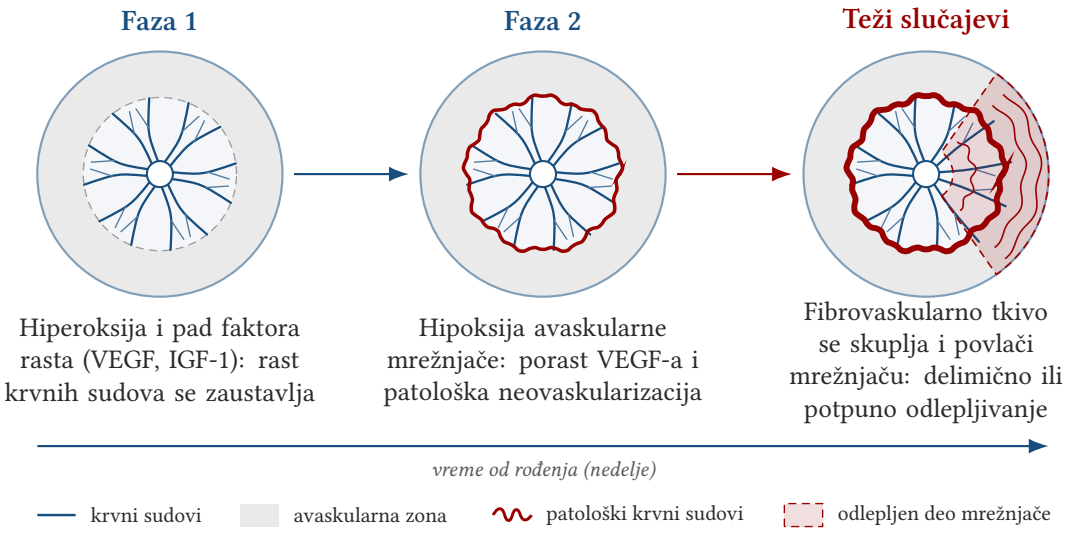
4.1 Deset gena sa najnižom p-vrednošću među genima sa $|\log_2 FC| > 1$. 22
4.2 Poređenje performansi metoda izbora obeležja (AUC, ugnježdena CV, $n = 5$ spoljnih iteracija). 23
4.3 AUC genetskog algoritma po spoljnoj iteraciji ugnježdene validacije. 24
4.4 Osetljivost finalnog fitness-a na hiperparametre genetskog algoritma. 26
4.5 Geni sa najvišom stopom selekcije kroz 10 nezavisnih pokretanja genetskog algoritma. 27

1

Uvod

1.1 Retinopatija prematuriteta – klinička slika i mehanizam

Retinopatija prematuriteta (ROP) je oboljenje mrežnjače koje pogađa prevremeno rođenu decu i predstavlja jedan od vodećih uzroka slepila u dečjem uzrastu [1]. Mehanizam nastanka bolesti odvija se u dve faze [2]. U prvoj fazi, prevremeno rođena beba prelazi iz sredine sa niskim nivoom kiseonika u materici u sredinu sa znatno više kiseonika (hiperoksija, odnosno višak kiseonika u tkivima, često pojačan dodatnom terapijom kiseonikom). Ova promena smanjuje nivo faktora rasta VEGF (vaskularni endotelni faktor rasta, signal koji podstiče rast krvnih sudova) i IGF-1 (insulinu sličan faktor rasta 1), pa se normalan rast krvnih sudova mrežnjače zaustavlja. U drugoj fazi, deo mrežnjače koji je ostao bez krvnih sudova trpi nedostatak kiseonika (hipoksija) i reaguje pojačanim lučenjem VEGF-a, što pokreće prekomeran i neuređen rast novih, patoloških krvnih sudova – proces koji može dovesti do odlepljivanja mrežnjače i trajnog gubitka vida.



Slika 1.1: Pojednostavljena šema dvofazne patogeneze ROP-a i mogućeg ishoda u težim slučajevima, prema Hellström et al. [2]. Krugovi predstavljaju mrežnjaču gledanu spreda, sa optičkim diskom u sredini.

Za kliničku procenu težine bolesti koristi se standardizovana međunarodna klasifikacija, čije

je aktuelno, treće izdanje objavljeno 2021. godine [3]. Skrining se prema važećim smernicama sprovodi kod dece rođene sa telesnom težinom ispod približno 1500 grama ili gestacijskom starošću od 30 nedelja ili manje. Pored ova dva osnovna kriterijuma, brojni dodatni faktori utiču na verovatnoću i težinu razvoja bolesti, što otvara prostor za istraživanje dodatnih, ranih prediktora rizika – jedan takav pravac, koji uključuje ulogu posteljice, opisan je u narednom odeljku.

1.2 Uloga posteljice u riziku od ROP-a

Posteljica je organ koji tokom trudnoće reguliše razmenu kiseonika i hranljivih materija između majke i fetusa. Pretpostavka je da stanje posteljice utiče na to koliko će vaskularni sistem bebe, uključujući mrežnjaču, biti otporan na postnatalne uslove koji dovode do ROP-a [4].

Ovu vezu su empirijski potvrdili Owen et al. [1], koji su pokazali da prisustvo placentne inflamacije (upalna promena tkiva posteljice, najčešće kao odgovor na infekciju plodovih ovojaka) kod majke statistički značajno smanjuje rizik od ROP-a kod deteta. Nadovezujući se na taj nalaz, Huang et al. [5] su analizom javno dostupnih podataka o genskoj ekspresiji u posteljici identifikovali četiri gena (*MMP25*, *CAPG*, *MCAM*, *B2M*) čija je aktivnost povezana sa razvojem ROP-a, i na osnovu njih napravili model za predikciju rizika.

Ovi nalazi ukazuju da placentna genska ekspresija sadrži merljiv signal o riziku od ROP-a – pravac istraživanja na koji se nadovezuje i ovaj rad, s tim što se ovde umesto standardnih statističkih metoda za izbor gena koristi genetski algoritam, opisan u Poglavlju 3.

1.3 Mašinsko učenje u predikciji ROP-a

Pored kliničke procene, razvijeno je nekoliko algoritamskih pristupa za rano predviđanje rizika od ROP-a na osnovu kliničkih i laboratorijskih parametara. Tabela 1.1 sumira tri najčešće korišćena pristupa.

Mašinsko učenje se sve više primenjuje i direktno na genomske podatke. Chen et al. [9] su primenom SVM-RFE, LASSO i Random Forest algoritama identifikovali gene relevantne za dijagnozu ROP-a udruženog sa sepsom, dok su Liu and Zhang [10] koristili slične metode na placentnoj transkriptomici za pronalaženje gena zajedničkih za gestacijski dijabetes i ROP. Nijedan od ovih radova ne koristi evolucione algoritme za izbor obeležja niti uključuje eksplicitnu komponentu objašnjivosti modela (npr. SHAP) – što predstavlja prostor za doprinos ovog rada, detaljnije razmotren u Poglavlju 2.

Tabela 1.1: Pregled odabranih kliničkih algoritama za predikciju ROP-a.

Algoritam	Osnovni princip	Izvor
WINROP	Prati nedeljni postnatalni prirast telesne mase; signalizira alarm pri odstupanju od očekivane putanje rasta.	Wu et al. [6]
G-ROP	Kombinuje porođajnu težinu, gestacijsku starost i postnatalni prirast mase u model sa šest kriterijuma.	Binenbaum et al. [7]
ROPScore / CHOP ROP	Slični pristupi zasnovani na kliničkim faktorima rizika, validirani na nezavisnim kohortama.	Piermarocchi et al. [8]

1.4 Motivacija i cilj rada

Motivacija za izbor ove teme proizašla je iz ličnog iskustva autorke, čiji je brat rođen prevremeno i razvio retinopatiju prematuriteta (ROP), koja je dovela do trajnog gubitka vida. Ovo iskustvo predstavljalo je neposredan podsticaj za izbor teme rada, dok je sama metodologija zasnovana isključivo na javno dostupnim podacima i standardnim, proverljivim postupcima mašinskog učenja.

Za razliku od prethodnog rada na istom skupu podataka [5], koji je gene birao linearnim regularizovanim metodama, ovaj rad koristi kombinatornu pretragu zasnovanu na genetskom algoritmu i procenjuje je ugnježdenom unakrsnom validacijom, koja izbor gena u potpunosti izoluje od podataka za testiranje.

Cilj rada je razvoj i evaluacija metode za izbor placentnih genskih biomarkera povezanih sa rizikom od ROP-a, zasnovane na genetskom algoritmu, uz primenu SHAP metode za objašnjavanje predikcija modela. Konkretni ciljevi su:

1. Sprovesti nezavisnu analizu diferencijalne ekspresije gena na javno dostupnom placentnom transkriptomskom skupu podataka, radi identifikacije kandidatnih gena.
2. Razviti genetski algoritam za izbor optimalne podgrupe gena za klasifikaciju ROP rizika, uz ugnježdeno unakrsno vrednovanje performansi kako bi se izbegao poznati problem *selection bias-a* pri radu sa malim uzorcima [11].
3. Uporediti performanse ovako dobijenog modela sa standardnim pristupima izbora obeležja.
4. Primeniti SHAP metodu za objašnjavanje doprinosa pojedinačnih gena predikciji modela.

Rad je inženjerski i metodološki orijentisan: njegov doprinos je u primeni i evaluaciji algoritama mašinskog učenja na strukturiranim biološkim podacima, dok medicinski problem

određuje cilj analize i način tumačenja rezultata.

2

Pregled literature

2.1 Placentni geni kao biomarkeri ROP-a

Owen et al. [1] su na kohorti prevremeno rođene dece pokazali statistički značajnu vezu između prisustva akutne placentne inflamacije i smanjenog rizika od ROP-a, pri čemu je ovaj protektivni efekat bio najizraženiji kod dece rođene bez prisustva preeklampsije kod majke. Tačan biološki mehanizam ovog protektivnog dejstva nije u potpunosti razjašnjen, ali autori pretpostavljaju da blaga placentna inflamacija može da ”pripremi” fetalni imuni i vaskularni sistem na postnatalne uslove, čineći ga otpornijim na kasnije patološke procese koji dovode do ROP-a. Nadovezujući se na ovaj nalaz, Huang et al. [5] su analizom istog skupa placentnih transkriptomskih podataka identifikovali četiri gena – *MMP25*, *CAPG*, *MCAM* i *B2M* – čija je ekspresija statistički povezana sa razvojem ROP-a. Autori su ove gene izabrali kombinacijom diferencijalne ekspresione analize i elastic-net regularizovane regresije, nakon čega su na osnovu njih i kliničkih promenljivih konstruisali nomogram – grafički alat za procenu rizika koji kombinuje nekoliko faktora u jedan skor. Iako su Huang et al. [5] pokazali da placentna ekspresija ovih gena nosi prediktivnu vrednost, njihov pristup izboru gena oslanja se na linearne statističke metode. Ovaj rad ispituje da li nelinearna, kombinatorna pretraga zasnovana na genetskom algoritmu može da identifikuje isti ili drugačiji, potencijalno robusniji skup gena, uz metodološki rigorozniju validaciju performansi.

2.2 Genetski algoritmi za izbor obeležja u genomici

Problem izbora malog broja relevantnih gena iz visokodimenzionih skupova podataka (tipično hiljade do desetine hiljada gena, uz svega desetine do stotine uzoraka) predstavlja jedan od centralnih izazova u bioinformatici. Genetski algoritmi se u ovom kontekstu koriste kao tzv. *wrapper* metoda izbora obeležja – umesto da procenjuju značaj svakog gena pojedinačno, oni evaluiraju performanse čitavih *kombinacija* gena, iterativno unapređujući te kombinacije kroz simulaciju procesa prirodne selekcije [12]. Prema pregledu Taha et al. [13], genetski algoritmi predstavljaju jedan od najčešće korišćenih pristupa u ovoj oblasti, sposoban da postigne visoku tačnost klasifikacije uz relativno mali broj izabranih gena. Deutsch [14] je među prvima primenio evolucione algoritme za pronalaženje optimalnih skupova gena u predikciji na osnovu mikroerej podataka, pokazujući da ovakav pristup može da postigne

tačnost klasifikacije uporedivu ili bolju od klasičnih statističkih metoda, uz značajno manji broj izabranih gena. Slični pristupi – uključujući hibridne metode koje kombinuju genetski algoritam sa mašinama sa potpornim vektorima (GA-SVM) ili k-najbližih suseda (GA-KNN) – pokazali su se uspešnim u klasifikaciji različitih tipova raka na osnovu mikroerej podataka [12].

Međutim, primena ovakvih metoda na skupove podataka sa malim brojem uzoraka (tipično ispod 100) nosi značajan metodološki rizik. Ambroise and McLachlan [11] su pokazali da ukoliko se izbor gena i procena performansi modela vrše na istim podacima – čak i uz primenu unakrsne validacije – dolazi do sistematskog precenjivanja tačnosti modela, pojave poznate kao *selection bias*. Ovaj problem je posebno izražen kod genetskih algoritama, koji kroz veliki broj iterativnih evaluacija efektivno „pretražuju" prostor mogućih rešenja u potrazi za onim koje najbolje odgovara konkretnoj podeli podataka na trening i test skup, što može dovesti do slučajnog pronalaženja kombinacije gena koja dobro generalizuje unutar te specifične podele, ali ne i na potpuno novim podacima. Imajući u vidu ovaj rizik, u ovom radu je genetski algoritam evaluiran korišćenjem ugnježdene unakrsne validacije (*nested cross-validation*), pri čemu je izbor gena u potpunosti izolovan od podataka korišćenih za konačnu procenu performansi modela – pristup detaljno opisan u Poglavlju 3.

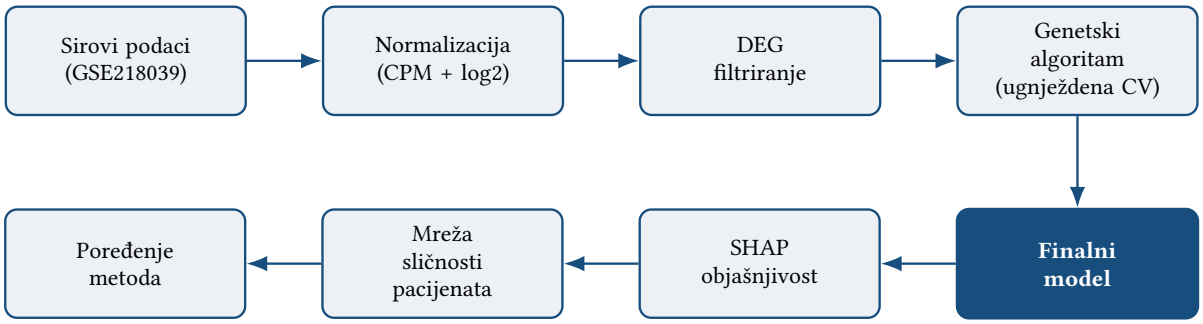
2.3 Objašnjiva veštačka inteligencija u analizi genske ekspresije

SHAP (*SHapley Additive exPlanations*) metoda [15] predstavlja jedan od najrasprostranjenijih pristupa za objašnjavanje predikcija modela mašinskog učenja. Zasnovana na konceptu Šeplijeve vrednosti iz teorije kooperativnih igara, SHAP za svaku pojedinačnu predikciju modela izračunava doprinos svakog ulaznog obeležja, omogućavajući i globalnu interpretaciju (koja obeležja su najvažnija u proseku) i lokalnu interpretaciju (zašto je model doneo baš tu odluku za konkretan slučaj). Primena SHAP metode na transkriptomske podatke placente pokazala se posebno korisnom u kontekstu drugih trudnoćom uslovljenih patologija. Chen et al. [16] su, koristeći multi-algoritamski pristup mašinskog učenja na dva placentna transkriptomska skupa podataka, identifikovali šest gena povezanih sa disregulacijom biogeneze ribozoma kao biomarkere rizika od preeklampsije, pri čemu je SHAP analiza otkrila da jedan od gena (*SUV39H1*) predstavlja dominantan faktor rizika, dok drugi (*GLUL*) ima protektivno dejstvo. Ovakav pristup – kombinacija mašinskog učenja i SHAP objašnjivosti na malim, javno dostupnim placentnim transkriptomskim skupovima podataka – direktno je metodološki analogan pristupu primenjenom u ovom radu, s tim što je ovde predmet istraživanja ROP, a ne preeklampsija.

3

Podaci i metodologija

Slika 3.1 prikazuje opšti tok rada opisan u ovom poglavlju – od sirovih podataka, preko predobrade i izbora obeležja, do finalnog modela i njegove evaluacije kroz nekoliko komplementarnih analiza.



Slika 3.1: Opšti tok metodologije primenjene u ovom radu.

3.1 Opis skupa podataka

Za potrebe ovog rada korišćen je javno dostupan skup podataka **GSE218039**, deponovan u Gene Expression Omnibus (GEO) bazi podataka [1]. Skup sadrži rezultate RNA sekvenciranja placentnog tkiva 30 prevremeno rođenih beba, od čega je kod 14 dijagnostikovan ROP, a 16 nije razvilo ovo oboljenje. Za svaki uzorak dostupni su podaci o ekspresiji 60.664 gena (izraženi kao broj očitavanja sekvenci, tzv. *read counts*), kao i prateće kliničke promenljive – pol deteta i prisustvo preeklampsije kod majke.

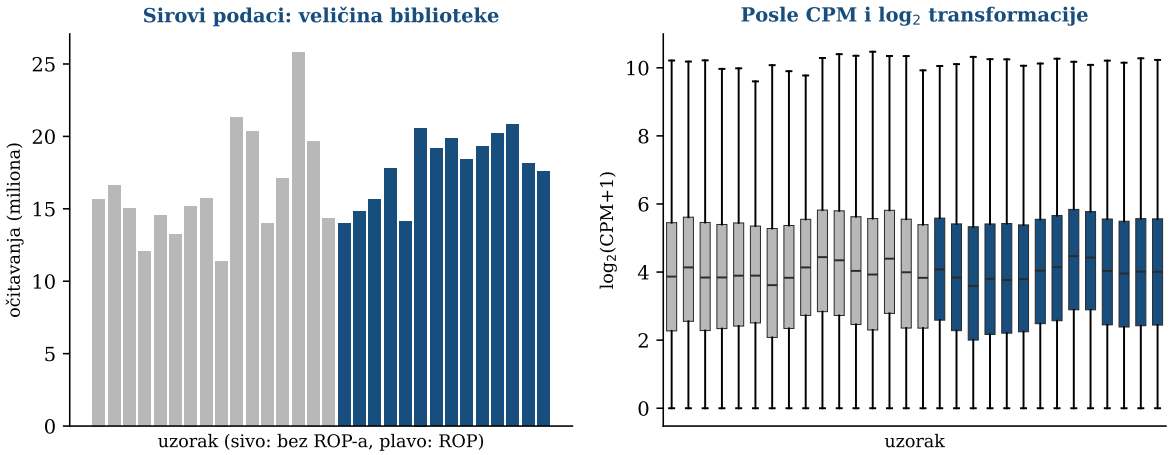
3.2 Predobrada i normalizacija podataka

Sirovi podaci o ekspresiji gena (*read counts*) nisu direktno uporedivi između uzoraka, jer ukupan broj očitavanja po uzorku varira usled tehničkih faktora vezanih za proces sekvenciranja, a ne usled stvarnih bioloških razlika. Radi otklanjanja ovog efekta, primenjena je normalizacija metodom CPM (*counts per million*), pri čemu je ekspresija svakog gena podeljena ukupnim brojem očitavanja u datom uzorku i pomnožena sa milion:

$$\mathrm{CPM}_{ij} = \frac{x_{ij}}{\sum_k x_{kj}} \times 10^6 \tag{3.1}$$

gde x_{ij} predstavlja broj očitavanja gena i u uzorku j. Nakon normalizacije, primenjena je logaritamska transformacija ($\log_2(\text{CPM} + 1)$), standardna praksa u analizi podataka ekspresije gena koja stabilizuje varijansu i svodi široki opseg vrednosti ekspresije na skalu pogodniju za dalju statističku analizu i mašinsko učenje.

Slika 3.2 ilustruje efekat normalizacije: ukupan broj očitavanja po uzorku kreće se od 11,4 do 25,8 miliona, dok su nakon CPM i $\log_2$ transformacije raspodele ekspresije između uzoraka uporedive.



Slika 3.2: Levo: ukupan broj očitavanja po uzorku u sirovim podacima. Desno: raspodela vrednosti $\log_2$(CPM+1) po uzorku za 15.307 eksprimiranih gena (CPM ≥ 1 u najmanje 15 uzoraka). Sivo: bez ROP-a, plavo: ROP.

3.3 Diferencijalna ekspresiona analiza

Kako bi se prostor pretrage za genetski algoritam sveo na razumnu, biološki relevantnu veličinu, sproveden je prvi korak filtriranja u vidu diferencijalne ekspresione analize (DEG). Za svaki od 60.664 gena, primenjen je Studentov t-test kojim se poredi prosečna log-CPM ekspresija između grupe dece sa ROP-om i grupe bez ROP-a. Nakon isključivanja gena sa nedovoljnom varijabilnošću ekspresije (za koje test nije bilo moguće izračunati), analiza je sprovedena na 42.638 gena.

S obzirom na veliki broj istovremeno sprovedenih statističkih testova, primenjena je Benjamini-Hochberg korekcija za višestruko testiranje (*false discovery rate*, FDR), kojom se kontroliše očekivani udeo lažno pozitivnih nalaza. Konačan skup kandidatnih gena za dalju analizu formiran je korišćenjem blažeg, nekorigovanog praga značajnosti ($p < 0.05$) u kombinaciji sa pragom veličine efekta ($|\log_2 FC| > 1$, gde FC označava *fold change*), pošto strogi korigovani prag ($p_{adj} < 0.05$) izdvaja svega nekoliko gena usled malog broja uzoraka. Ovakav dvostepeni pristup – filtriranje na osnovu blažeg statističkog praga, praćeno rigoroznijom validacijom u narednim koracima – uobičajena je praksa u analizi genomskih podataka sa malim brojem uzoraka.

Primenom opisanih kriterijuma izdvojen je 121 gen. Ovom skupu pridodata su i četiri gena identifikovana u prethodnom istraživanju [5] (*MMP25*, *CAPG*, *MCAM*, *B2M*), nezavisno od toga da li su samostalno zadovoljili kriterijume filtriranja; kako se *CAPG* već nalazio među 121 genom, dodata su preostala tri gena. Ovim je formiran konačan skup od 124 kandidatna gena koji predstavlja ulazni prostor pretrage za genetski algoritam opisan u narednom odeljku (Sekcija 3.4); metodološki detalji vezani za ponovnu primenu ovog postupka u okviru procene performansi opisani su u Sekciji 3.5.

3.4 Genetski algoritam za izbor gena

3.4.1 Reprezentacija rešenja

Svako potencijalno rešenje problema izbora gena predstavljeno je binarnim vektorom (hromozomom), gde svaka pozicija odgovara jednom genu iz kandidatnog skupa formiranog u prethodnom koraku. Vrednost 1 na i-toj poziciji označava da je odgovarajući gen uključen u posmatranu kombinaciju, dok vrednost 0 označava njegovo isključenje. U ilustrativnom pokretanju nad svim uzorcima kandidatni skup ima 124 gena, pa je dužina hromozoma 124:

$$c = (c_1, c_2, \ldots, c_{124}), \quad c_i \in \{0, 1\} \tag{3.2}$$

Dužina hromozoma uvek odgovara veličini kandidatnog skupa koji je ulaz u dati poziv genetskog algoritma. Unutar ugnježdene validacije (Sekcija 3.5) ona varira po spoljnoj iteraciji u skladu sa DEG filtriranjem te iteracije (93–227 gena).

Prilikom inicijalizacije populacije, broj uključenih gena po hromozomu nasumično se bira iz opsega $[5, 20]$, čime se ograničava prostor pretrage na biološki i klinički interpretabilne veličine skupa obeležja, izbegavajući i preterano mali (nedovoljno informativan) i preterano veliki (teško interpretabilan) broj izabranih gena.

3.4.2 Funkcija prilagođenosti

Kvalitet svakog hromozoma c procenjuje se funkcijom prilagođenosti (*fitness function*), koja preslikava kombinaciju gena u skalarnu vrednost koja odražava njenu prediktivnu korisnost:

$$f(c) = \mathrm{AUC}(c) - \lambda \cdot |c| \tag{3.3}$$

gde je $\mathrm{AUC}(c)$ površina ispod ROC krive (*Area Under the ROC Curve*) modela treniranog isključivo na genima uključenim u hromozom c, procenjena unakrsnom validacijom, $|c|$ predstavlja broj uključenih gena (Hamingova težina hromozoma), a $\lambda = 0{,}001$ je koeficijent koji blago penalizuje hromozome sa većim brojem izabranih gena. Ovakva formulacija favorizuje ne samo prediktivnu tačnost, već i parsimoničnost (jednostavnost) izabranog skupa obeležja, u

skladu sa principom da manji broj gena olakšava biološku interpretaciju i kliničku primenljivost rezultata. AUC se može tumačiti kao verovatnoća da model nasumično izabranoj bebi sa ROP-om dodeli viši rizik nego nasumično izabranoj bebi bez ROP-a: vrednost 0,5 odgovara slučajnom pogađanju, a 1 savršenom razdvajanju. Za procenu AUC(c) tokom evolucije, koristi se Random Forest klasifikator sa unakrsnom validacijom (detaljno opisano u Sekciji 3.5), primenjen isključivo na trening podskup podataka, čime se sprečava direktno curenje informacija iz test skupa u proces izbora obeležja.

3.4.3 Genetski operatori

Evolucija populacije hromozoma kroz generacije sprovodi se primenom tri standardna genetska operatora.

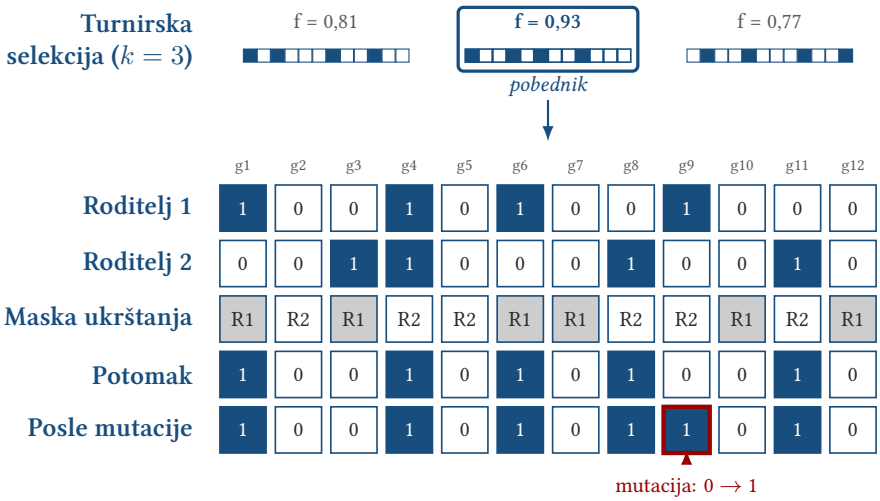
Selekcija. Za izbor roditeljskih hromozoma korišćena je turnirska selekcija (*tournament selection*) sa veličinom turnira $k = 3$: iz populacije se nasumično bira k hromozoma, a hromozom sa najvišom vrednošću funkcije prilagođenosti među njima proglašava se pobednikom i koristi kao roditelj. Ovakav pristup, za razliku od direktnog izbora najboljih hromozoma, održava raznovrsnost populacije i smanjuje rizik od preuranjene konvergencije ka lokalnom optimumu.

Ukrštanje. Za par izabranih roditelja $c^{(1)}$ i $c^{(2)}$, primenjuje se uniformno ukrštanje (*uniform crossover*): za svaku poziciju $i \in \{1, \ldots, 124\}$, vrednost potomka $c_i^{(o)}$ nasumično se preuzima od jednog od dva roditelja sa jednakom verovatnoćom:

$$c_i^{(o)} = \begin{cases} c_i^{(1)} & \text{sa verovatnoćom } 0{,}5 \\ c_i^{(2)} & \text{sa verovatnoćom } 0{,}5 \end{cases} \tag{3.4}$$

Mutacija. Nakon ukrštanja, na potomka se primenjuje mutacija: za svaku poziciju i, vrednost $c_i^{(o)}$ invertuje se (iz 0 u 1 ili obrnuto) sa verovatnoćom $p_m = 0{,}02$, nezavisno za svaku poziciju. Mutacija unosi novu genetsku varijabilnost koja ne može nastati isključivo ukrštanjem postojećih hromozoma, sprečavajući stagnaciju pretrage na ograničenom podskupu prostora rešenja.

Slika 3.3 prikazuje primer ukrštanja i mutacije na skraćenom hromozomu od 12 gena.



Slika 3.3: Primer genetskih operatora na hromozomu od 12 gena (u radu 124). Turnirska selekcija bira hromozom sa najvišom vrednošću funkcije prilagođenosti među tri nasumično izabrana ($k = 3$; vrednosti su ilustrativne). Plavo polje označava uključen gen. Maska ukrštanja određuje za svaku poziciju da li potomak gen preuzima od prvog (R1) ili drugog roditelja (R2), a mutacija zatim invertuje jednu poziciju (crveni okvir).

Elitizam. Radi očuvanja najboljeg pronađenog rešenja, hromozom sa najvišom vrednošću funkcije prilagođenosti u svakoj generaciji prenosi se nepromenjen u narednu generaciju, nezavisno od procesa selekcije, ukrštanja i mutacije.

3.4.4 Algoritam u celini

Algoritam 1 sumira kompletan tok genetskog algoritma primenjenog u ovom radu. Populacija veličine $N = 30$ evoluira kroz $G = 30$ generacija, pri čemu se u svakoj generaciji, pored elitnog hromozoma, generiše preostalih $N - 1$ potomaka primenom selekcije, ukrštanja i mutacije opisanih u prethodnoj sekciji.

Konvergencija algoritma ilustrovana je na Slici 4.4 (Poglavlje 4), gde se vrednost funkcije prilagođenosti najboljeg hromozoma u populaciji prati kroz sve generacije za nekoliko kombinacija hiperparametara (N, p_m), analiziranih u okviru ispitivanja osetljivosti modela (Sekcija 4.3).

3.5 Ugnježdena unakrsna validacija

Procena prediktivnih performansi modela koji uključuje korak izbora obeležja zahteva posebnu metodološku pažnju. Ukoliko se izbor obeležja i procena performansi sprovode nad istim podacima – čak i uz primenu standardne k-struke unakrsne validacije – dolazi do pojave poznate kao *selection bias* [11], koja sistematski precenjuje stvarnu prediktivnu sposobnost modela. Ovaj rizik je posebno izražen kod genetskih algoritama, koji kroz veliki broj iterativnih evaluacija (u ovom radu do 900 evaluacija po pokretanju) efektivno pretražuju

Algorithm 1 Genetski algoritam za izbor gena

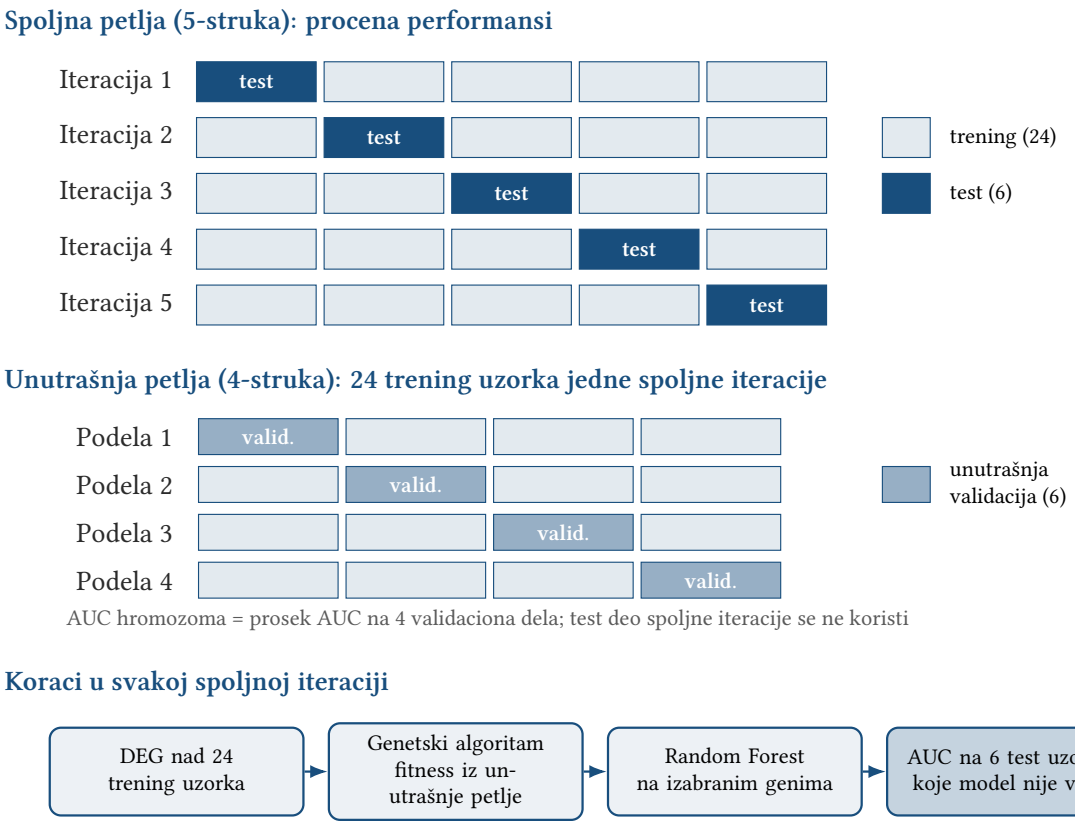
Inicijalizovati populaciju P od N nasumičnih hromozoma
for generacija $g = 1$ do G **do**
    for svaki hromozom $c \in P$ **do**
        Izračunati $f(c)$ (Jednačina 3.3)
    $c^* \leftarrow$ hromozom sa najvišim $f(c)$ u P
    $P' \leftarrow \{c^*\}$ ▷ elitizam
    while $|P'| < N$ **do**
        $c^{(1)} \leftarrow$ TurnirskaSelekcija(P)
        $c^{(2)} \leftarrow$ TurnirskaSelekcija(P)
        $c^{(o)} \leftarrow$ Ukrštanje$(c^{(1)}, c^{(2)})$
        $c^{(o)} \leftarrow$ Mutacija$(c^{(o)})$
        $P' \leftarrow P' \cup \{c^{(o)}\}$
    $P \leftarrow P'$
return hromozom sa najvišim $f(c)$ u finalnoj populaciji P

prostor mogućih rešenja u potrazi za onim koje najbolje odgovara konkretnoj podeli podataka, što može rezultovati pronalaženjem kombinacije obeležja koja dobro generalizuje isključivo unutar te specifične podele.

Kako bi se ovaj rizik izbegao, primenjena je **ugnježdena unakrsna validacija** (*nested cross-validation*), koja uspostavlja dva nezavisna nivoa podele podataka:

- **Spoljna petlja** (5-struka, stratifikovana): skup od 30 uzoraka deli se na 5 podskupova; u svakoj iteraciji, jedan podskup (6 uzoraka) izdvaja se isključivo za finalnu procenu performansi, dok preostala 4 podskupa (24 uzorka) čine trening skup te iteracije.
- **Unutrašnja petlja** (4-struka): unutar trening skupa svake spoljne iteracije, genetski algoritam sprovodi kompletnu evoluciju (uključujući ponovno izvođenje DEG analize opisane u Sekciji 3.3, isključivo nad tih 24 uzorka), pri čemu se funkcija prilagođenosti svakog hromozoma procenjuje unutrašnjom unakrsnom validacijom.

Slika 3.4 prikazuje ovaj postupak.



Slika 3.4: Šema ugnježdene unakrsne validacije. Spoljna petlja deli 30 uzoraka na pet delova i u svakoj iteraciji izdvaja 6 uzoraka za konačno testiranje. Unutrašnja petlja deli preostala 24 trening uzorka na četiri dela i koristi se samo za procenu funkcije prilagođenosti unutar genetskog algoritma. Test uzorci spoljne iteracije ne učestvuju ni u izboru gena ni u treniranju.

Nakon završetka evolucije unutar spoljne iteracije, hromozom sa najvišom vrednošću funkcije prilagođenosti koristi se za treniranje finalnog modela te iteracije, čije se performanse potom procenjuju na izdvojenom test podskupu (6 uzoraka) – podacima koje ni genetski algoritam ni proces treniranja nisu ni u jednom trenutku koristili. Ovaj postupak ponavlja se za svih 5 spoljnih iteracija, a izveštena mera performansi predstavlja prosek AUC vrednosti dobijenih na 5 nezavisnih test podskupova.

Bitno je napomenuti da veličina kandidatnog skupa gena dobijenog DEG filtriranjem varira između spoljnih iteracija (u opsegu od 93 do 227 gena u sprovedenim eksperimentima), s obzirom na to da se DEG analiza sprovodi nad različitim trening podskupovima od po 24 uzorka. Ova varijabilnost je očekivana posledica ponovnog izvođenja postupka izbora obeležja nad različitim podskupovima malog skupa podataka.

3.6 Poređenje sa alternativnim metodama izbora obeležja

Radi objektivne procene doprinosa genetskog algoritma, njegove performanse upoređene su sa četiri standardne metode izbora obeležja, primenjene pod identičnim uslovima – istim

ugnježdenim protokolom validacije opisanim u prethodnoj sekciji, uključujući ponovno izvođenje DEG analize unutar svake spoljne iteracije:

- **Random Forest (baseline)**: klasifikator treniran nad kompletnim skupom kandidatnih gena, bez dodatnog koraka izbora obeležja, korišćen kao referentna tačka.
- **LASSO** (L_1 regularizacija): logistička regresija sa L_1 penalizacijom koeficijenata, koja vrši implicitan izbor obeležja svođenjem koeficijenata nebitnih gena na tačno nulu.
- **Ridge** (L_2 regularizacija): logistička regresija sa L_2 penalizacijom, korišćena kao dodatna referentna tačka bez eksplicitnog izbora obeležja.
- **Elastic-net** (kombinacija L_1 i L_2 regularizacije): metoda korišćena u prethodnom istraživanju [5] za izbor placentnih biomarkera ROP-a.

Za metode zasnovane na regularizaciji, jačina regularizacije (parametar C), a za elastic-net i odnos L_1/L_2 komponenti (parametar $l1_ratio$), određivani su pretragom po mreži vrednosti (*grid search*) unutar unutrašnje petlje ugnježdene validacije, analogno postupku optimizacije genetskog algoritma.

3.7 SHAP objašnjivost

Radi tumačenja predikcija finalnog modela, primenjena je SHAP (*SHapley Additive exPlanations*) metoda [15], zasnovana na Šeplijevim vrednostima iz teorije kooperativnih igara. Za svaku pojedinačnu predikciju, SHAP dodeljuje svakom ulaznom obeležju (genu) vrednost doprinosa koja predstavlja njegov uticaj na odstupanje predikcije od očekivane (prosečne) vrednosti modela:

$$\hat{y}(x) = \phi_0 + \sum_{i=1}^{M} \phi_i \tag{3.5}$$

gde je $\hat{y}(x)$ predikcija modela za uzorak x, ϕ_0 očekivana (prosečna) predikcija modela nad celim skupom podataka, ϕ_i SHAP vrednost i-tog gena za posmatrani uzorak, a M ukupan broj gena u modelu. Za izračunavanje SHAP vrednosti korišćen je `TreeExplainer`, implementacija optimizovana za modele zasnovane na stablima odlučivanja (uključujući Random Forest), koja omogućava egzaktno (ne aproksimativno) izračunavanje Šeplijevih vrednosti za ovu klasu modela.

Finalni model, korišćen za SHAP analizu, treniran je primenom genetskog algoritma nad kompletnim skupom od 30 uzoraka (Sekcija 3.4). Ovde je bitno jasno razdvojiti dve odvojene upotrebe modela u ovom radu: *evaluacioni model*, treniran isključivo na trening podskupovima unutar ugnježdene validacije (Sekcija 3.5), čije performanse na neviđenim test podskupovima predstavljaju izveštanu meru tačnosti (Sekcija 4.2); i *finalni interpretacioni model*, treniran nad celim skupom podataka nakon što je evaluacija već nezavisno završena, čija je jedina svrha SHAP analiza, ne dodatna procena tačnosti.

3.8 Mreža sličnosti pacijenata

Kao dodatna, nezavisna provera prisustva signala u izabranom skupu gena, konstruisana je mreža sličnosti pacijenata (*Patient Similarity Network*, PSN) [17], u kojoj čvorovi predstavljaju 30 uzoraka (beba), a ivice povezuju uzorke sa sličnim profilom ekspresije finalnog skupa gena.

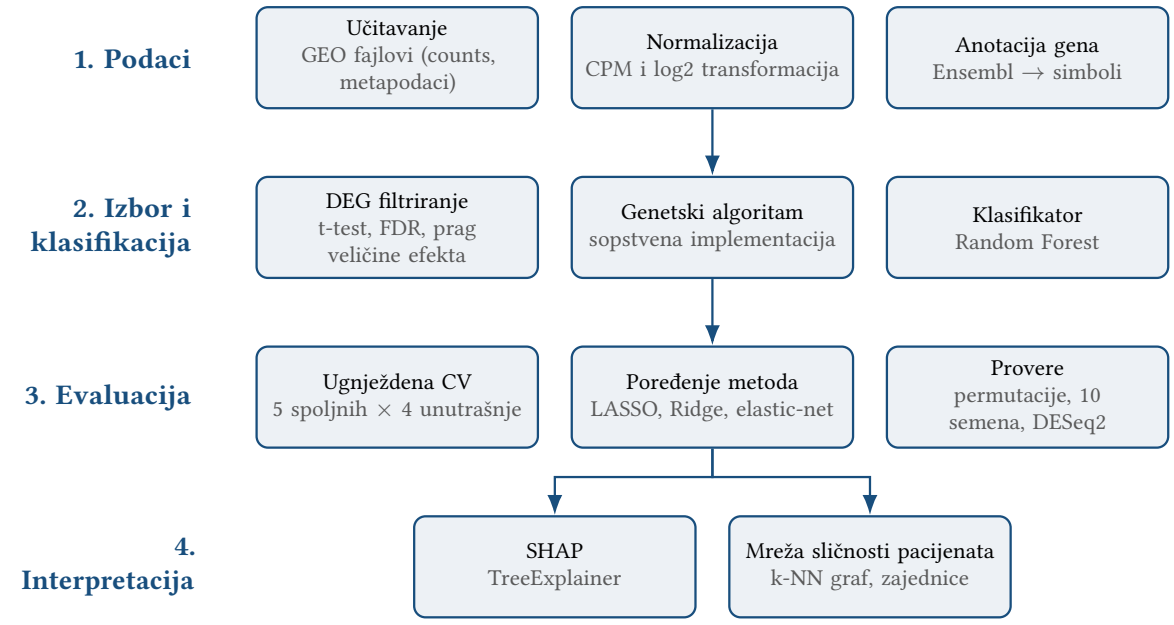
Sličnost između svaka dva uzorka x_j i x_k izračunata je primenom Gausovog jezgra nad euklidskim rastojanjem njihovih standardizovanih vektora ekspresije:

$$s_{jk} = \exp\left(-\frac{\|x_j - x_k\|^2}{2\sigma^2}\right) \tag{3.6}$$

gde je σ medijana svih parnih rastojanja u skupu podataka. Na osnovu ove matrice sličnosti, konstruisan je k-najbližih-suseda graf ($k = 5$) – svaki uzorak povezan je sa 5 uzoraka kojima je najsličniji. Nad ovako konstruisanim grafom primenjen je Luvenov algoritam za detekciju zajednica (*Louvain community detection*), a podudarnost otkrivenih zajednica sa stvarnim ROP statusom kvantifikovana je Prilagođenim Rand indeksom (*Adjusted Rand Index*, ARI).

3.9 Implementacija

Sve analize u ovom radu implementirane su u programskom jeziku Python 3.11, u Jupyter okruženju, kao niz modula koji prate tok prikazan na Slici 3.1. Radi preglednosti, Slika 3.5 prikazuje isti postupak iz ugla softverske organizacije: četiri sloja, od učitavanja podataka do interpretacije, pri čemu svaki sloj koristi izlaz prethodnog.



Slika 3.5: Slojevita organizacija implementacije. Svaki sloj odgovara jednoj fazi analize i koristi izlaz prethodnog sloja.

Tabela 3.1 navodi biblioteke korišćene u pojedinim slojevima. Genetski algoritam je jedini

deo postupka koji je implementiran od nule: selekcija, ukrštanje, mutacija, elitizam i funkcija prilagođenosti napisani su kao zasebne funkcije nad binarnim vektorima, uz standardne Python module *random* i *NumPy*, bez specijalizovane biblioteke za evolucione algoritme. Funkcija prilagođenosti poziva klasifikator i unakrsnu validaciju iz biblioteke *scikit-learn*.

Tabela 3.1: Biblioteke korišćene u implementaciji i njihova uloga.

Biblioteka	**Uloga**
pandas, NumPy	učitavanje tabela ekspresije, CPM normalizacija i log2 transformacija, matrice obeležja
SciPy, statsmodels	Studentov t-test i Mann-Whitney test, Benjamini-Hochberg korekcija
scikit-learn	Random Forest, logistička regresija (L1, L2, elastic-net), pretraga po mreži, stratifikovana unakrsna validacija, AUC
SHAP	*TreeExplainer* za izračunavanje Šeplijevih vrednosti
mygene	anotacija Ensembl identifikatora simbolima gena
pydeseq2	eksplorativna provera sa metodom DESeq2 (Sekcija 5.3)

Najzahtevniji deo postupka je funkcija prilagođenosti. Jedno pokretanje genetskog algoritma obuhvata 900 evaluacija hromozoma (30 hromozoma kroz 30 generacija), a svaka evaluacija trenira Random Forest sa 100 stabala unutar 4-struke unakrsne validacije. Unutar ugnježdene validacije, koja je predstavljena Algoritmom 2, algoritam se pokreće po jednom za svaku od pet spoljnih iteracija, što daje $5 \times 900 \times 4 = 18\,000$ treniranja modela za jednu procenu performansi. Analiza stabilnosti (10 pokretanja sa različitim semenima) i permutacioni test (500 permutacija) dodaju još desetine hiljada treniranja. Zbog toga je u funkciji prilagođenosti korišćen manji broj stabala (100) nego u finalnom modelu (200). Sva izvršavanja sprovedena su na standardnom personalnom računaru, bez grafičke kartice.

Algorithm 2 Ugnježdena unakrsna validacija sa izborom gena

Podeliti 30 uzoraka na 5 stratifikovanih podskupova ▷ spoljna petlja
for svaki podskup $k = 1$ do 5 **do**
    $S_{test} \leftarrow$ podskup k; $S_{train} \leftarrow$ preostala 4 podskupa
    Izvršiti DEG analizu nad S_{train} i formirati kandidatni skup K_k (uključujući i četiri gena iz literature)
    $c_k^* \leftarrow \text{GenetskiAlgoritam}(S_{train}, K_k)$ ▷ fitness: AUC, 4-struka CV
    Trenirati Random Forest nad S_{train} koristeći gene iz c_k^*
    $\text{AUC}_k \leftarrow$ AUC dobijen na S_{test}
return prosek i standardna devijacija vrednosti $\text{AUC}_1, \ldots, \text{AUC}_5$

Ponovljivost je obezbeđena fiksiranjem generatora slučajnih brojeva: parametar *random_state* postavljen je na 42 za Random Forest i za podele u unakrsnoj validaciji, a Python i NumPy generatori inicijalizovani su istim semenom u finalnom pokretanju, odnosno

semenima od 0 do 9 u analizi stabilnosti. Fiksna semena garantuju iste rezultate samo u istom softverskom okruženju: između verzija biblioteka (npr. scikit-learn i SHAP) mogu se javiti manje razlike, pa je za tačnu reprodukciju potrebno očuvati verzije korišćene u radu.

4

Rezultati

4.1 Diferencijalna ekspresija gena

Tabela 4.1 prikazuje deset gena sa najnižom p-vrednošću među onima koji zadovoljavaju prag veličine efekta $|\log_2 FC| > 1$ (Sekcija 3.3), zajedno sa njihovim vrednostima log2 fold change (log2FC). Pozitivna vrednost log2FC označava povišenu ekspresiju gena kod dece sa ROP-om u odnosu na kontrolnu grupu.

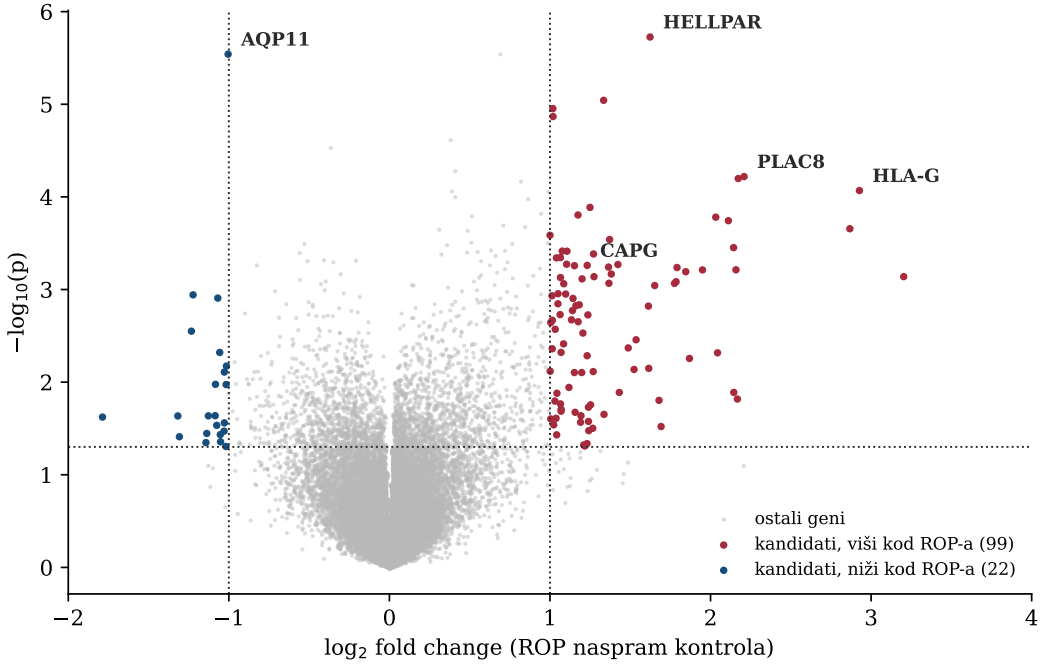
Tabela 4.1: Deset gena sa najnižom p-vrednošću među genima sa $|\log_2 FC| > 1$.

Gen	**log2FC**	**p-vrednost**	p_{adj}
HELLPAR	1.62	2×10^{-6}	0.041
AQP11	-1.00	3×10^{-6}	0.041
RTN4RL2	1.33	9×10^{-6}	0.095
HLA-V	1.02	1.1×10^{-5}	0.095
TLE6	1.02	1.4×10^{-5}	0.096
PLAC8	2.21	6.0×10^{-5}	0.243
NOG	2.17	6.3×10^{-5}	0.243
HLA-G	2.93	8.5×10^{-5}	0.252
ASAP3	1.25	1.3×10^{-4}	0.308
CLDN19	1.17	1.6×10^{-4}	0.321

Od 42.638 gena podvrgnutih testiranju, 3 gena zadovoljava strogi korigovani prag značajnosti ($p_{adj} < 0{,}05$): *HELLPAR*, *AQP11* i *HCG4*. Poslednji nije prikazan u Tabeli 4.1 jer ne zadovoljava prag veličine efekta ($\log_2 FC = 0{,}69$). Primenom blažeg kriterijuma opisanog u Sekciji 3.3 (nekorigovano $p < 0{,}05$ i $|\log_2 FC| > 1$) skup kandidata obuhvata 121 gen. Od četiri gena identifikovana u prethodnom istraživanju [5] (*MMP25*, *CAPG*, *MCAM*, *B2M*), samo *CAPG* samostalno zadovoljava ovaj kriterijum. Preostala tri nisu u skupu od 121 gena, ali su dodata u kandidatni skup na osnovu prethodnog istraživanja nad istom kohortom, čime je formiran konačni skup od 124 gena.

Slika 4.1 prikazuje rezultate DEG analize za sve testirane gene. Od 121 kandidata, 99 ima višu, a 22 nižu ekspresiju kod dece sa ROP-om. Dva gena sa najnižom p-vrednošću, HELLPAR (log2FC = 1,62) i AQP11 (log2FC = -1,00), jedini su koji ostaju značajni i posle korekcije za višestruko testiranje (padj = 0,041). Isti geni su i najstabilnije birani genetskim algoritmom (Sekcija 4.4). Ostali geni finalnog skupa potiču iz šireg opsega DEG ranga, što pokazuje da

algoritam pored najjačih pojedinačnih signala bira i gene koji doprinose u kombinaciji sa drugima.



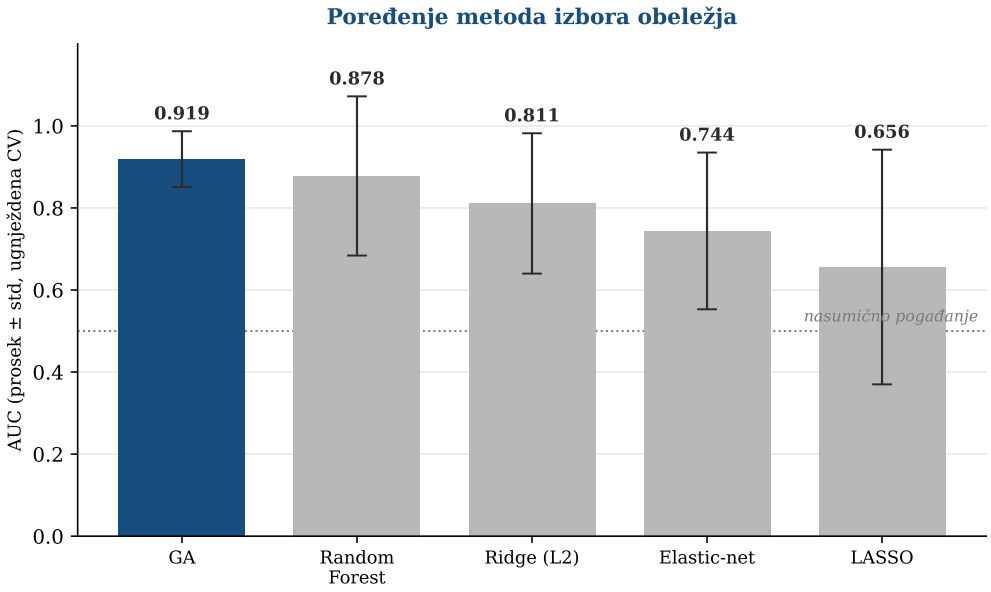
Slika 4.1: Vulkan grafik diferencijalne ekspresione analize (42.638 gena). Tačkaste linije označavaju pragove $p = 0{,}05$ i $|\log_2 FC| = 1$; obojene tačke su 121 kandidatni gen.

4.2 Performanse genetskog algoritma i poređenje metoda

Tabela 4.2 sumira performanse genetskog algoritma i četiri alternativne metode izbora obeležja, procenjene identičnim protokolom ugnježdene unakrsne validacije opisanim u Sekciji 3.5. Slika 4.2 vizuelno prikazuje iste rezultate.

Tabela 4.2: Poređenje performansi metoda izbora obeležja (AUC, ugnježdena CV, $n = 5$ spoljnih iteracija).

Metod	AUC (prosek $\pm$ std)	Broj obeležja
Genetski algoritam	**0.919 $\pm$ 0.068**	**6–10 (prosek 8.2)**
Random Forest (baseline)	0.878 $\pm$ 0.194	124 (fiksno)
Ridge (L2)	0.811 $\pm$ 0.171	svi kandidati
Elastic-net	0.744 $\pm$ 0.191	43–135
LASSO (L1)	0.656 $\pm$ 0.286	9–16



Slika 4.2: Poređenje AUC performansi genetskog algoritma i alternativnih metoda izbora obeležja. Prikazane su prosečne vrednosti i standardna devijacija preko 5 spoljnih iteracija ugnježdene validacije.

Genetski algoritam ostvaruje najviši prosečan AUC uz istovremeno najnižu standardnu devijaciju među svim testiranim metodama, što ukazuje na veću stabilnost performansi između različitih podela podataka, pored postizanja veće tačnosti sa znatno manjim brojem izabranih gena u odnosu na sve alternativne pristupe.

Tabela 4.3 prikazuje AUC vrednosti genetskog algoritma po pojedinačnoj spoljnoj iteraciji, ilustrujući varijabilnost performansi karakterističnu za male test podskupove (6 uzoraka po iteraciji).

Tabela 4.3: AUC genetskog algoritma po spoljnoj iteraciji ugnježdene validacije.

Spoljna iteracija	AUC	Broj izabranih gena
1	0.875	10
2	0.833	6
3	1.000	7
4	0.889	9
5	1.000	9

4.2.1 Permutacioni test

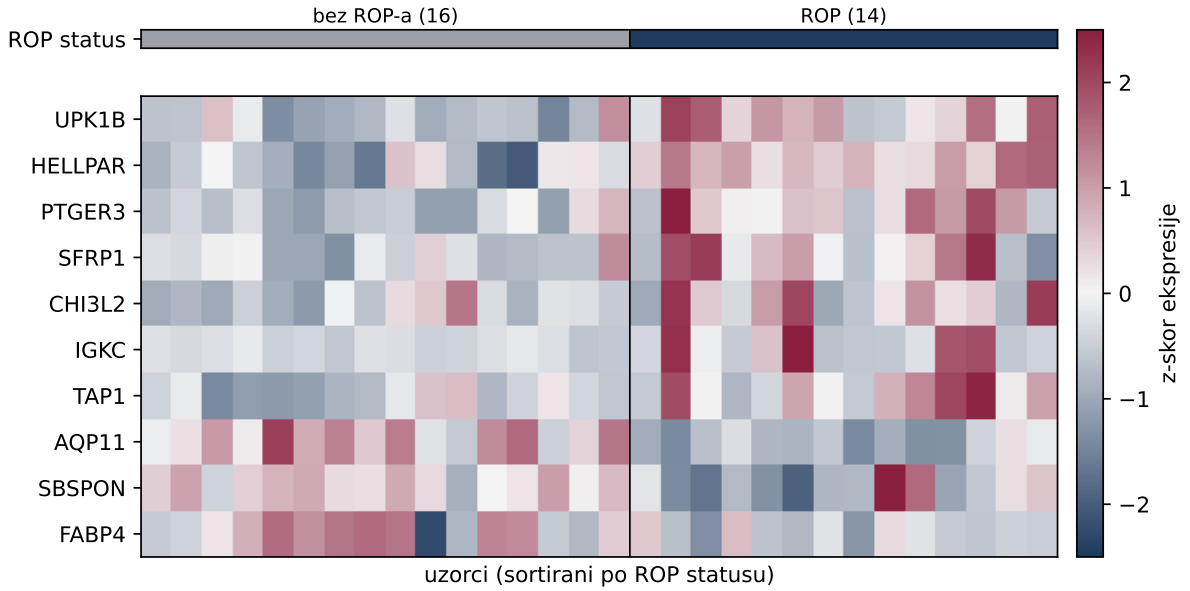
Radi formalne provere da izmerena prediktivna sposobnost nije posledica slučajnosti, sproveden je permutacioni test: ROP oznake su nasumično permutovane 500 puta, a za svaku permutaciju izračunat je AUC finalnog skupa gena istom unakrsnom validacijom. Prosečan AUC na permutovanim oznakama iznosio je $0{,}485 \pm 0{,}152$ – blizu vrednosti 0.5 koja odgovara

nasumičnom pogađanju, kako se i očekuje kada stvarna veza između obeležja i ishoda ne postoji. Referentna AUC vrednost u ovom testu (1,0) izračunata je nad istim podacima na kojima su geni izabrani, te je stoga precenjena; poštena procena performansi data je u Sekciji 4.2 (AUC $= 0{,}919$). Udeo permutacija koje su dostigle ili premašile ovu konzervativniju vrednost i dalje iznosio je $p = 0{,}002$, što potvrđuje da izmereni signal statistički značajno odstupa od nulte distribucije nezavisno od toga koja se referentna vrednost koristi.

4.2.2 Provera uticaja unapred poznatih gena

Četiri gena iz prethodnog istraživanja [5] identifikovana su na istom skupu podataka (GSE218039), pa njihovo ručno uključivanje u kandidatni skup svake spoljne iteracije (Sekcija 3.3) teorijski unosi blagu vezu sa test podacima te iteracije. Radi provere uticaja ove odluke, ceo ugnježđeni postupak ponovljen je bez ručnog uključivanja ova četiri gena, oslanjajući se isključivo na DEG rezultate svake spoljne iteracije. Prosečan AUC iznosio je $0{,}908 \pm 0{,}084$, gotovo identičan originalnom rezultatu ($0{,}919 \pm 0{,}068$), što ukazuje da ručno uključivanje ova četiri gena nije imalo praktičan uticaj na izmerene performanse.

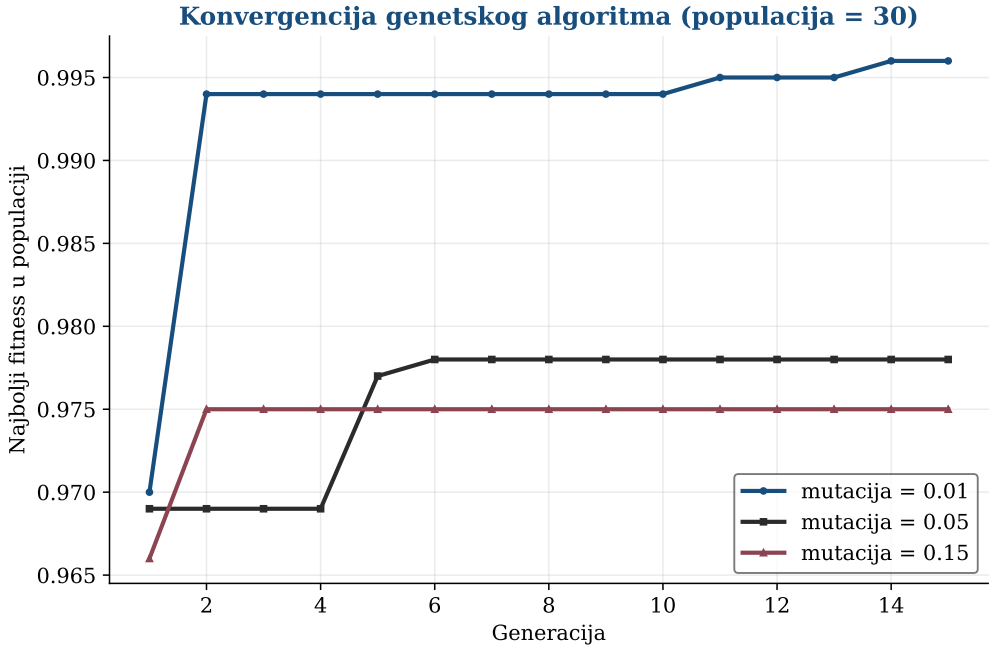
Slika 4.3 prikazuje ekspresiju 10 gena finalnog modela (Sekcija 3.7) kod svih 30 uzoraka.



Slika 4.3: Ekspresija 10 gena finalnog modela (z-skor po genu), sa uzorcima sortiranim po ROP statusu. Geni su izabrani nad svih 30 uzoraka, pa vizuelna razlika između grupa ne predstavlja procenu prediktivnih performansi; ta procena data je u Sekciji 4.2.

4.3 Konvergencija i osetljivost na hiperparametre

Slika 4.4 prikazuje konvergenciju vrednosti funkcije prilagođenosti najboljeg hromozoma kroz generacije, za tri vrednosti verovatnoće mutacije ($p_m \in \{0{,}01, 0{,}05, 0{,}15\}$), pri fiksnoj veličini populacije $N = 30$.



Slika 4.4: Konvergencija genetskog algoritma za različite vrednosti verovatnoće mutacije. Niža stopa mutacije ($p_m = 0{,}01$) omogućava postepeniju, ali dugoročno superiorniju konvergenciju u odnosu na više stope mutacije, koje dovode do preranog zaustavljanja na lokalnom optimumu.

Tabela 4.4 sumira finalne vrednosti funkcije prilagođenosti za sve testirane kombinacije veličine populacije i verovatnoće mutacije, nakon 15 generacija.

Tabela 4.4: Osetljivost finalnog fitness-a na hiperparametre genetskog algoritma.

Populacija (N)	**Mutacija (p_m)**	**Finalni fitness**
10	0.01	0.990
10	0.05	0.964
10	0.15	0.953
30	0.01	0.996
30	0.02	0.987
30	0.05	0.978
30	0.15	0.975
60	0.01	0.997
60	0.05	0.983
60	0.15	0.994

Rezultati pokazuju da najniža testirana stopa mutacije (pm = 0,01) daje najbolje krajnje rešenje pri svim veličinama populacije, dok povećanje veličine populacije sa 30 na 60 donosi zanemarljivo poboljšanje ($+0{,}001$) uz duplo veću računsku cenu. Vrednost $p_m = 0{,}02$, korišćena u glavnim eksperimentima ovog rada, pokazuje finalni fitness od 0.987 – između najbolje ($p_m = 0{,}01$, 0.996) i srednje ($p_m = 0{,}05$, 0.978) testirane vrednosti, čime se potvrđuje da je predstavljala razuman izbor za glavne eksperimente.

4.4 Stabilnost izbora gena

Radi procene robusnosti izbora gena, genetski algoritam je nezavisno pokrenut 10 puta sa različitim semenima generatora slučajnih brojeva, na kompletnom skupu od 30 uzoraka. Tabela 4.5 prikazuje gene koji su izabrani u najmanje 5 od 10 pokretanja.

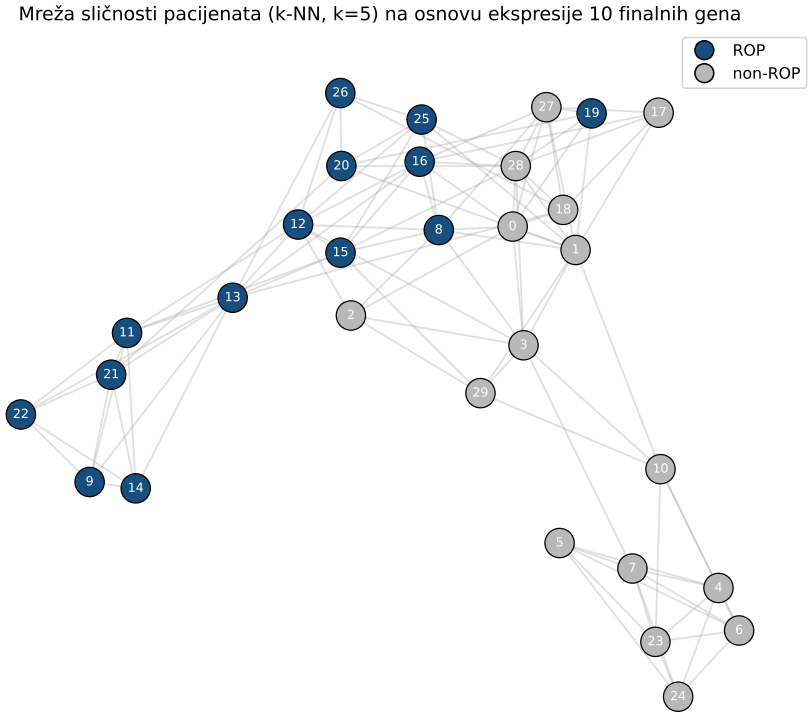
Tabela 4.5: Geni sa najvišom stopom selekcije kroz 10 nezavisnih pokretanja genetskog algoritma.

Gen	**Broj pokretanja (od 10)**
HELLPAR	10
AQP11	7

Nijedan drugi gen iz kandidatnog skupa nije dostigao prag od 5 pokretanja, uključujući nijedan od četiri gena identifikovana u prethodnom istraživanju [5]. Ova nestabilnost izbora obeležja između pojedinačnih pokretanja u skladu je sa poznatim ograničenjima genomskih analiza na malim uzorcima [11], dok je gen HELLPAR u glavnoj konfiguraciji izdvojen kao najstabilnije obeležje (izabran u svih 10 pokretanja), što je dodatno razmotreno u Poglavlju 5.

4.5 Eksplorativna analiza sličnosti pacijenata

Slika 4.5 prikazuje mrežu sličnosti pacijenata konstruisanu na osnovu ekspresije finalnog skupa od 10 gena (Sekcija 3.8). Dobijeni graf je povezan (30 čvorova, 102 ivice, jedna povezana komponenta).

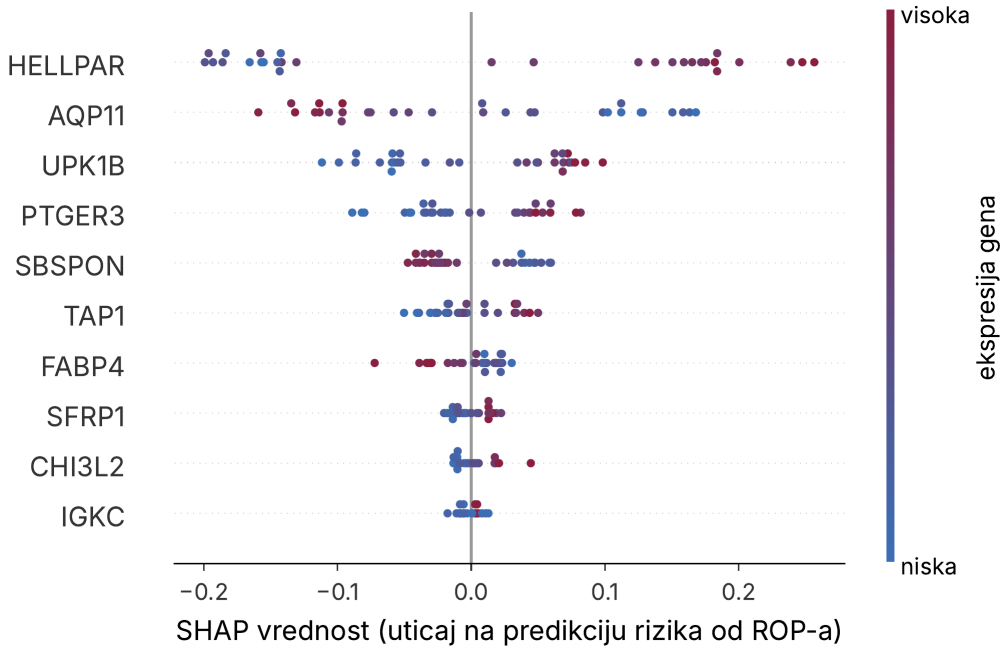


Slika 4.5: Mreža sličnosti pacijenata na osnovu ekspresije finalnog skupa gena. Čvorovi predstavljaju uzorke, obojeni prema ROP statusu (tamnoplavo – ROP, sivo – bez ROP-a); ivice povezuju uzorke sa najsličnijim profilom ekspresije ($k = 5$).

Primenom Luvenovog algoritma za detekciju zajednica, identifikovane su 4 zajednice unutar mreže. Podudarnost ovih zajednica sa stvarnim ROP statusom, kvantifikovana Prilagođenim Rand indeksom, iznosi ARI $= 0{,}173$. Ovo je eksplorativan, hipotezno-generišući nalaz, ne formalna validacija modela – nenadgledano grupisanje ne koristi kliničke oznake, i pozitivna, umerena vrednost ARI ukazuje na prisustvo strukture konzistentne sa ROP statusom, dok istovremeno odražava i druge izvore biološke varijabilnosti u podacima.

4.6 SHAP objašnjivost

Slika 4.6 prikazuje SHAP vrednosti finalnog modela (Sekcija 3.7) za svih 10 gena, poređanih po opadajućem prosečnom apsolutnom uticaju na predikciju.



Slika 4.6: SHAP objašnjivost finalnog modela. Svaka tačka predstavlja jedan uzorak; položaj na horizontalnoj osi pokazuje uticaj na predikciju rizika, a boja označava vrednost ekspresije posmatranog gena kod tog uzorka (plava – niska, bordo – visoka).

Najveći i najdosledniji uticaj na predikciju modela pokazuje gen HELLPAR. Uzorci sa visokom ekspresijom (bordo tačke) gotovo isključivo doprinose povećanju predviđenog rizika, dok uzorci sa niskom ekspresijom (plave tačke) dosledno doprinose njegovom smanjenju, uz jasno razdvajanje i svega nekoliko uzoraka blizu nulte vrednosti. Ovakva doslednost izostaje kod ostalih gena u modelu. Kombinacija najviše stabilnosti izbora kroz nezavisna pokretanja genetskog algoritma u glavnoj konfiguraciji (Sekcija 4.4) i najjačeg, najdoslednijeg doprinosa predikciji u SHAP analizi čini HELLPAR najistaknutijim nalazom glavne analize, čija je biološka interpretacija razmotrena u Poglavlju 5. Proverena je moguća konfundiranost sa kliničkim promenljivim. Ekspresija HELLPAR ne razlikuje se statistički značajno između polova ($p = 0{,}47$, Mann-Whitney test) niti između uzoraka sa i bez preeklampsije kod majke ($p = 0{,}46$, Mann-Whitney test). Pol nije značajno neuravnotežen između ROP i kontrolne grupe ($p = 0{,}73$, Fisherov egzaktni test), kao ni preeklampsija (6 od 15 naspram 8 od 15 slučajeva ROP-a, $p = 0{,}72$, Fisherov egzaktni test).

5

Diskusija

Ovaj rad je ispitao da li genetski algoritam može da identifikuje mali, prediktivan skup placentnih gena povezanih sa rizikom od ROP-a, uz metodološki rigoroznu evaluaciju performansi. Glavni nalazi mogu se sumirati na sledeći način: (1) genetski algoritam je, u ugnježdenoj unakrsnoj validaciji, postigao viši prosečan AUC ($0{,}919 \pm 0{,}068$) uz niži broj obeležja od svih testiranih alternativnih metoda; (2) permutacioni test, isključivanje ručno uključenih gena iz literature i zamena DEG metode (pri istoj veličini kandidatnog skupa) ne ukazuju na to da je ovaj rezultat posledica slučajnosti ili tih izbora; (3) gen HELLPAR je u glavnoj konfiguraciji analize izdvojen kao najstabilnije i najuticajnije obeležje kroz nezavisna pokretanja algoritma i SHAP analizu.

5.1 Poređenje sa prethodnim istraživanjem

Za razliku od Huang et al. [5], koji su za izbor gena koristili elastic-net regularizovanu regresiju, ovaj rad primenjuje genetski algoritam kao kombinatornu, nelinearnu alternativu. Direktno poređenje pod identičnim uslovima ugnježdene validacije (Sekcija 4.2) pokazuje da genetski algoritam nadmašuje elastic-net na ovom skupu podataka ($0{,}919$ naspram $0{,}744$), uz znatno manji broj izabranih gena. Bitno je napomenuti da je četiri gena identifikovana u radu Huang et al. [5] (*MMP25*, *CAPG*, *MCAM*, *B2M*) prethodno izvedeno iz istog skupa podataka (GSE218039) korišćenog i u ovom radu; njihovo uključivanje u kandidatni skup ovog rada stoga ne predstavlja nezavisnu spoljašnju potvrdu, već iskorišćavanje prethodnog znanja nad istom kohortom. Provera uticaja ove odluke (Sekcija 4.2.2) pokazuje da isključivanje ovih gena iz kandidatnog skupa dovodi do zanemarljive promene performansi ($0{,}908$ naspram $0{,}919$), što ukazuje da glavni rezultat ovog rada ne zavisi dominantno od tog prethodnog znanja, već da genetski algoritam samostalno pronalazi informativan skup obeležja direktno iz podataka.

Nijedan od četiri gena identifikovana u radu Huang et al. [5] nije zadržan u finalnom skupu gena ovog rada (Sekcija 4.4), niti se pojavljuje među stabilno biranim genima kroz nezavisna pokretanja algoritma. Ovo je u skladu sa dobro dokumentovanom nestabilnošću genskih potpisa dobijenih na malim uzorcima – različite, metodološki ispravne analize istog skupa podataka mogu identifikovati različite, ali podjednako prediktivne skupove obeležja, usled visoke korelisanosti gena unutar istih bioloških puteva.

5.2 Biološka interpretacija - gen HELLPAR

Gen HELLPAR izdvaja se kao jedini gen koji je u glavnoj konfiguraciji analize dosledno biran u svih 10 nezavisnih pokretanja genetskog algoritma (Sekcija 4.4) i istovremeno pokazuje najjači i najdosledniji doprinos predikciji u SHAP analizi (Sekcija 4.6). Ovaj gen ima i najjaču pojedinačnu razliku u ekspresiji između grupa u DEG analizi. Tri kriterijuma, statistička razlika, stabilnost izbora i uticaj na predikciju, ukazuju na isti gen. Ovi kriterijumi nisu međusobno nezavisni, jer su izračunati nad istim uzorcima, a genetski algoritam bira iz skupa prethodno filtriranog po statističkoj značajnosti. Njihovo slaganje stoga pokazuje doslednost analize, a ne nezavisnu potvrdu nalaza.

HELLPAR je dugačka nekodirajuća RNK (lncRNA) smeštena u regionu hromozoma 12q23 koji je povezan sa HELLP sindromom, teškim oblikom preeklampsije [18]. Eksprimirana je u ekstraviloznom trofoblastu, ćelijama posteljice koje urastaju u zid materice, i povezuje se sa regulacijom njihovog ćelijskog ciklusa i invazije [18]. Viša ekspresija HELLPAR kod dece koja su razvila ROP stoga može odražavati izmenjenu funkciju posteljice. To se uklapa u hipotezu da placentni faktori utiču na rizik od ROP-a (Sekcija 1.2).

Drugi po stabilnosti gen, AQP11 (akvaporin 11), ima nižu ekspresiju kod dece sa ROP-om. Ovaj kanal u endoplazmatskom retikulumu propušta vodu i vodonik-peroksid i učestvuje u održavanju redoks ravnoteže ćelije, što ga povezuje sa oksidativnim stresom, mehanizmom poznatim iz prve faze patogeneze ROP-a (Sekcija 1.1).

Važno je precizno formulisati domet ovih nalaza. U ovom skupu podataka ekspresija HELLPAR ne razlikuje se između uzoraka sa i bez preeklampsije (Sekcija 4.6), pa signal nije prosto posredna mera preeklampsije kod majke. Biološka verovatnoća ne predstavlja dokaz uzročnosti. Nalaz treba interpretirati kao osnovu za hipotezu o ulozi HELLPAR u riziku od ROP-a, koja zahteva nezavisnu validaciju, a ne kao potvrđen biomarker.

5.3 Ograničenja rada

Rezultati ovog rada podležu nekolicini značajnih ograničenja koja moraju biti uzeta u obzir prilikom njihove interpretacije.

Veličina uzorka. Skup podataka obuhvata svega 30 uzoraka, što je karakteristično za ovaj tip javno dostupnih transkriptomskih podataka, ali predstavlja fundamentalno ograničenje za donošenje generalizovanih zaključaka. Test podskupovi u ugnježdenoj validaciji sadrže svega 6 uzoraka, usled čega pojedinačne AUC vrednosti po iteraciji (Tabela 4.3) predstavljaju grube, diskretne procene sa ograničenom statističkom snagom.

Stabilnost izbora gena. Kao što je pokazano u Sekciji 4.4, izbor gena između nezavisnih pokretanja genetskog algoritma je nestabilan – samo dva gena (*HELLPAR*, *AQP11*) dostižu prag od 5 od 10 pokretanja. Finalni skup od 10 gena, korišćen za SHAP analizu i konstrukciju mreže sličnosti pacijenata, predstavlja rezultat jednog konkretnog pokretanja algoritma

(fiksiran slučajnim semenom), a ne konsenzusni, robustan nalaz. Ovo ograničenje je inherentno problemu izbora obeležja na malim, visokodimenzionim skupovima podataka [11] i ne umanjuje validnost izmerenih performansi (koje su nezavisno procenjene ugnježdenom validacijom), ali zahteva oprez pri interpretaciji identiteta pojedinačnih izabranih gena.

Permutacioni test. Sproveden permutacioni test (Sekcija 4.2) procenjuje značajnost finalnog, fiksnog skupa gena, ali ne ponavlja kompletan postupak izbora obeležja (DEG i genetski algoritam) za svaku permutaciju, usled računske zahtevnosti takvog pristupa. Rezultat testa stoga treba tumačiti kao potvrdu da izabrani skup gena nosi signal iznad slučajnog nivoa, a ne kao formalan dokaz značajnosti celokupnog postupka izbora obeležja.

Nedostatak eksterne validacije. Svi rezultati odnose se na jedan, javno dostupan skup podataka. Nezavisna validacija na eksternoj kohorti neophodna je pre bilo kakvog zaključka o kliničkoj primenljivosti pronađenih obeležja.

Metodološki izbori podložni daljem ispitivanju. Diferencijalna ekspresiona analiza u ovom radu zasniva se na Studentovom t-testu primenjenom na log-transformisane CPM vrednosti; specijalizovane metode za RNK-sekvenciranje (npr. DESeq2, limma-voom), koje eksplicitno modeluju odnos srednje vrednosti i varijanse karakterističan za podatke o broju očitavanja, mogle bi predstavljati metodološki rafinisaniji izbor. Slično, unutrašnja unakrsna validacija unutar funkcije prilagođenosti genetskog algoritma koristi fiksiranu podelu na foldove, što teorijski otvara mogućnost blagog prilagođavanja algoritma specifičnoj podeli tokom velikog broja iterativnih evaluacija. Konačno, hiperparametri genetskog algoritma (Sekcija 4.3) testirani su pojedinačno, bez ponavljanja preko više slučajnih semena, usled čega predstavljaju inženjersku analizu osetljivosti, a ne formalnu optimizaciju.

Preliminarna, eksplorativna provera zamenila je t-test metodom DESeq2 u koraku DEG filtriranja. Kada je kandidatni skup ograničen na istu veličinu kao u glavnoj analizi (121 gen sa najnižom p-vrednošću uz $|\log_2 FC| > 1$, plus četiri poznata gena), ugnježdeni AUC iznosio je $0{,}883 \pm 0{,}079$, u opsegu glavnog rezultata ($0{,}919 \pm 0{,}068$). Sa strogim pragom $p_{adj} < 0{,}05$ kandidatni skupovi su bili veći (183–473 gena po iteraciji), a AUC niži i varijabilniji ($0{,}789 \pm 0{,}218$). Identitet najčešće biranih gena razlikovao se od glavne analize. Procena performansi stoga nije bitno osetljiva na izbor DEG metode pri istoj veličini kandidatnog skupa, ali je identitet stabilno biranih gena osetljiv na konfiguraciju DEG koraka, pa HELLPAR treba tumačiti kao hipotezu koja važi za glavnu konfiguraciju.

5.4 Budući rad

Na osnovu identifikovanih ograničenja, budući rad bi trebalo da obuhvati: validaciju pronađenih obeležja na nezavisnoj, eksternoj kohorti; ponavljanje ugnježdene validacije sa više slučajnih podela podataka (*repeated nested cross-validation*) radi preciznije procene varijabilnosti performansi; primenu specijalizovanih metoda diferencijalne ekspresije za RNK-sekvenciranje; i eksplicitnu analizu doprinosa dostupnih kliničkih promenljivih (pol,

preeklampsija) u odnosu na genski signal, radi provere da li placentna genska ekspresija nosi prediktivnu vrednost nezavisno od poznatih kliničkih faktora rizika.

6

Zaključak

Ovaj rad je razvio i evaluirao metodu zasnovanu na genetskom algoritmu za izbor placentnih genskih biomarkera povezanih sa rizikom od retinopatije prematuriteta, uz primenu SHAP metode za objašnjavanje predikcija. Sprovedena je nezavisna diferencijalna ekspresiona analiza na javno dostupnom placentnom transkriptomskom skupu podataka, na osnovu koje je genetski algoritam identifikovao mali, prediktivan skup gena, čije su performanse procenjene metodološki rigoroznom ugnježdenom unakrsnom validacijom kako bi se izbegao poznati problem *selection bias-a* karakterističan za analize sa malim brojem uzoraka.

Genetski algoritam je, u poštenoj evaluaciji, ostvario prosečan AUC od $0{,}919$, nadmašujući sve testirane alternativne metode izbora obeležja (Random Forest, LASSO, Ridge, elastic-net) uz značajno manji broj izabranih gena. Permutacioni test, isključivanje ručno uključenih gena iz literature i zamena DEG metode pri istoj veličini kandidatnog skupa ne ukazuju na to da je ovaj rezultat posledica slučajnosti ili tih izbora. U glavnoj konfiguraciji analize, gen HELLPAR izdvojen je kao jedini dosledno stabilan i najuticajniji nalaz kroz nezavisna pokretanja algoritma i SHAP analizu. Reč je o nekodirajućoj RNK posteljice povezanoj sa HELLP sindromom, što daje biološki verodostojnu vezu između funkcije posteljice i rizika od ROP-a. Nalaz ipak zahteva nezavisnu validaciju pre bilo kakvog zaključka o njegovoj biološkoj ulozi.

Rad je prevashodno metodološki doprinos: pokazuje da kombinatorna, evoluciona pretraga prostora obeležja može da identifikuje kompaktan, prediktivan skup gena na malom, visokodimenzionom transkriptomskom skupu podataka, uz rigoroznu kontrolu poznatih izvora precenjivanja performansi. Ograničenja rada – pre svega mali broj uzoraka i nestabilnost izbora pojedinačnih gena između nezavisnih pokretanja – jasno ograničavaju domet zaključaka na nivo metodološkog dokaza izvodljivosti (*proof-of-concept*), a ne kliničke validacije.

Budući rad treba da obuhvati validaciju na nezavisnoj eksternoj kohorti, ponovljenu ugnježdenu validaciju radi preciznije procene varijabilnosti, i eksplicitnu analizu doprinosa dostupnih kliničkih promenljivih genskom signalu. Ovaj rad predstavlja korak u tom pravcu, otvarajući prostor za dalje istraživanje primene evolucionih algoritama u analizi malih, visokodimenzionih biomedicinskih skupova podataka.

Bibliografija

[1] L. A. Owen, C. Zhang, K. Shirer, L. Carroll *et al.*, "Placental inflammation significantly correlates with reduced risk for retinopathy of prematurity," *American Journal of Pathology*, vol. 193, no. 11, pp. 1776–1788, 2023.

[2] A. Hellström, L. E. H. Smith, and O. Dammann, "Retinopathy of prematurity," *The Lancet*, vol. 382, no. 9902, pp. 1445–1457, 2013.

[3] M. F. Chiang, G. E. Quinn, A. R. Fielder *et al.*, "International classification of retinopathy of prematurity, third edition," *Ophthalmology*, vol. 128, no. 10, pp. e51–e68, 2021.

[4] M. Pammi, N. Aghaeepour, and J. Neu, "Multiomics, artificial intelligence, and precision medicine in perinatology," *Pediatric Research*, 2023.

[5] D. Huang, R. Gan, Y. Zhang, Z. Chen, Y. Bai, W. Zhu, D. Luo, Y. Yang, Z. Liu, and Y. Deng, "Construction of a prediction model for retinopathy of prematurity based on placenta-derived genes and clinical variables," *Translational Pediatrics*, 2026.

[6] C. Wu, C. Löfqvist, L. E. H. Smith, D. K. VanderVeen, and A. Hellström, "Importance of early postnatal weight gain for normal retinal angiogenesis in very preterm infants: A multicenter study analyzing weight velocity deviations for the prediction of retinopathy of prematurity," *Archives of Ophthalmology*, vol. 130, no. 8, pp. 992–999, 2012.

[7] G. Binenbaum, E. F. Bell, P. Donohue, G. Quinn, J. Shaffer, L. A. Tomlinson, and G.-s. Ying, "Development of modified screening criteria for retinopathy of prematurity: Primary results from the postnatal growth and retinopathy of prematurity study," *JAMA Ophthalmology*, vol. 136, no. 9, pp. 1034–1040, 2018.

[8] S. Piermarocchi, S. Bini, F. Martini, M. Berton *et al.*, "Predictive algorithms for early detection of retinopathy of prematurity," *Acta Ophthalmologica*, 2017.

[9] H. Chen, E. Chen, Y. Lu, and Y. Xu, "Identification of immune-related genes in diagnosing retinopathy of prematurity with sepsis through bioinformatics analysis and machine learning," *Frontiers in Genetics*, 2023.

[10] L. Liu and C. Zhang, "Unraveling shared diagnostic biomarkers: Integrated bioinformatics identification of CGB7, MYCNUTR, and GPR32 in gestational diabetes mellitus and retinopathy of prematurity," *The Tohoku Journal of Experimental Medicine*, 2026.

[11] C. Ambroise and G. J. McLachlan, "Selection bias in gene extraction on the basis of microarray gene-expression data," *Proceedings of the National Academy of Sciences*, vol. 99, no. 10, pp. 6562–6566, 2002.

[12] N. Almugren and H. Alshamlan, "A survey on hybrid feature selection methods in microarray gene expression data for cancer classification," *IEEE Access*, 2019.

[13] Z. Y. Taha, A. A. Abdullah, and T. A. Rashid, "Optimizing feature selection with genetic algorithms: A review of methods and applications," *Knowledge and Information Systems*, 2025.

[14] J. M. Deutsch, "Evolutionary algorithms for finding optimal gene sets in microarray prediction," *Bioinformatics*, vol. 19, no. 1, pp. 45–52, 2003.

[15] S. M. Lundberg and S.-I. Lee, "A unified approach to interpreting model predictions," *Advances in Neural Information Processing Systems*, vol. 30, 2017.

[16] J. Chen, D. Zhang, C. Zhu, L. Lin, K. Ye, Y. Hua *et al.*, "Explainable machine learning reveals ribosome biogenesis biomarkers in preeclampsia risk prediction," *Frontiers in Genetics*, 2025.

[17] S. Pai and G. D. Bader, "Patient similarity networks for precision medicine," *Journal of Molecular Biology*, vol. 430, no. 18, pp. 2924–2938, 2018.

[18] M. van Dijk, H. K. Thulluru, J. Mulders, O. J. Michel, A. Poutsma, S. Windhorst, G. Kleiverda, D. Sie, A. M. A. Lachmeijer, and C. B. M. Oudejans, "HELLP babies link a novel lincrna to the trophoblast cell cycle," *Journal of Clinical Investigation*, vol. 122, no. 11, pp. 4003–4011, 2012.